



大数据大带宽推动云计算应用与创新

第五届中国云计算大会

大数据的系统架构支持

@林仕鼎

2013/6/6

互联网服务的典型技术特点



超大规模


快速迭代

大数据规模

数据总量	• 100~1000PB
数据处理量	• 10~100PB/天
网页	• 千亿~万亿
索引	• 百亿~千亿
更新量	• 十亿~百亿/天
请求	• 十亿~百亿/天
日志	• 100TB~1PB/天

百度的数据规模

快速迭代是互联网产品的主要创新手段

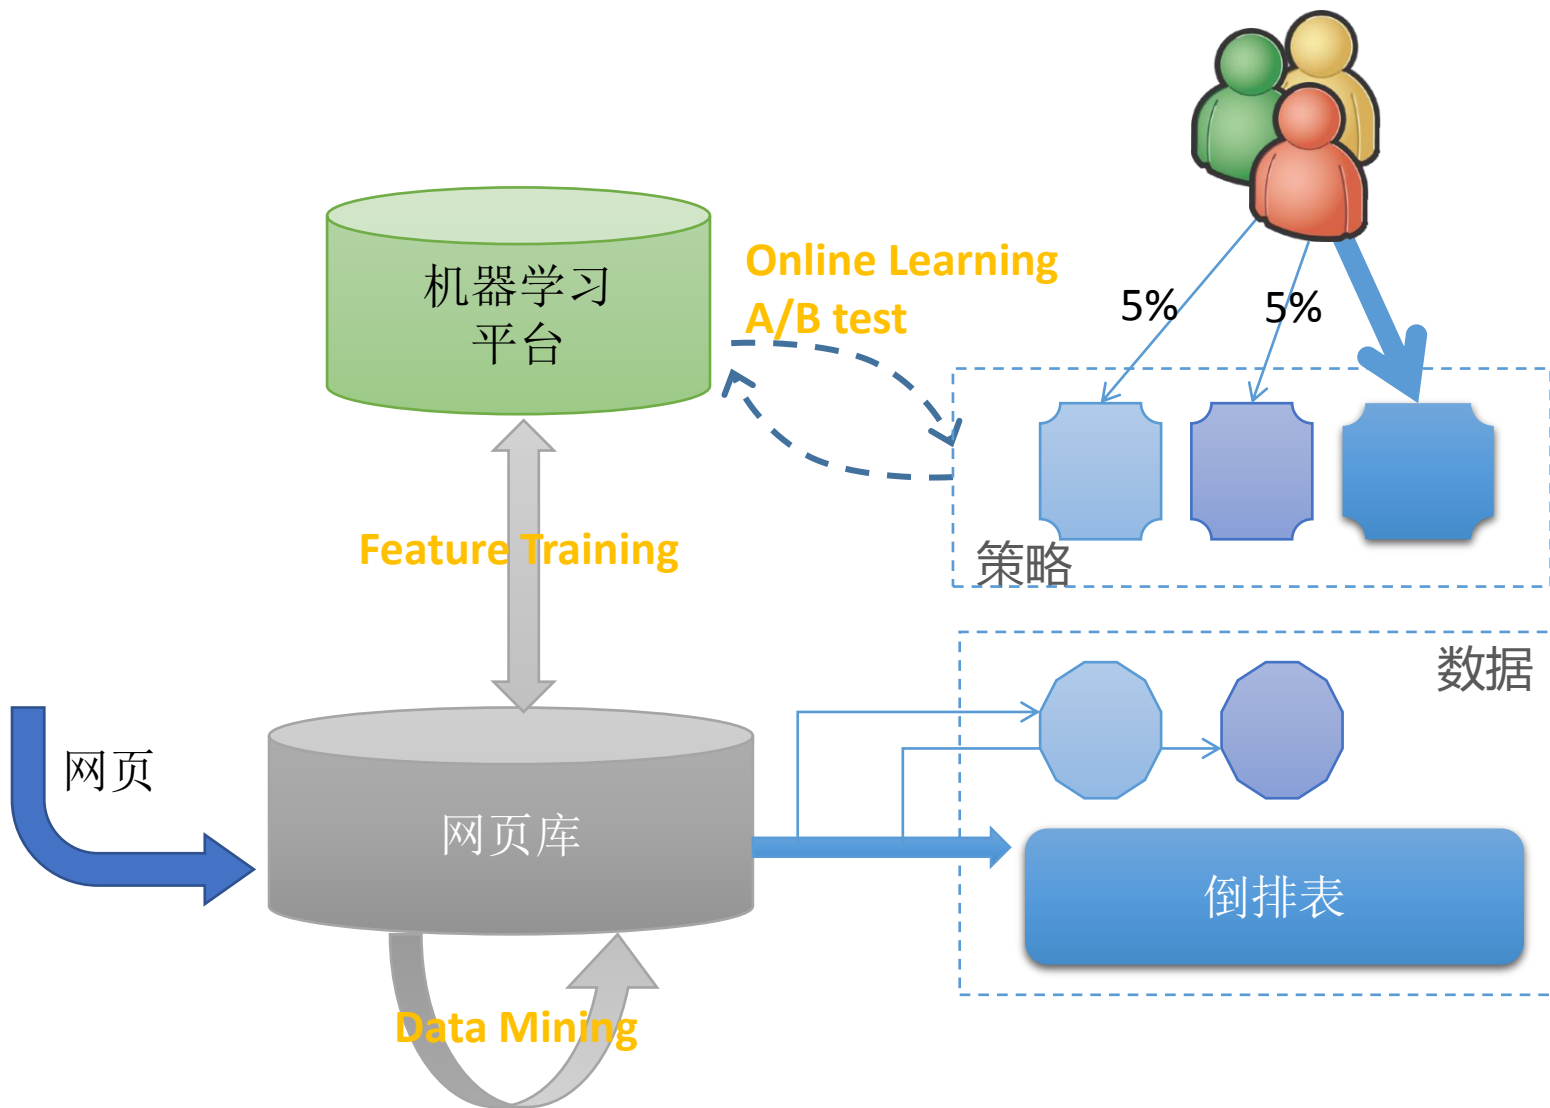


通过反馈来验证算法优劣



离线分析与在线实验相结合

搜索引擎的迭代



互联网产品的迭代

A/B测试，持续优化



互联网服务

enable

数据智能

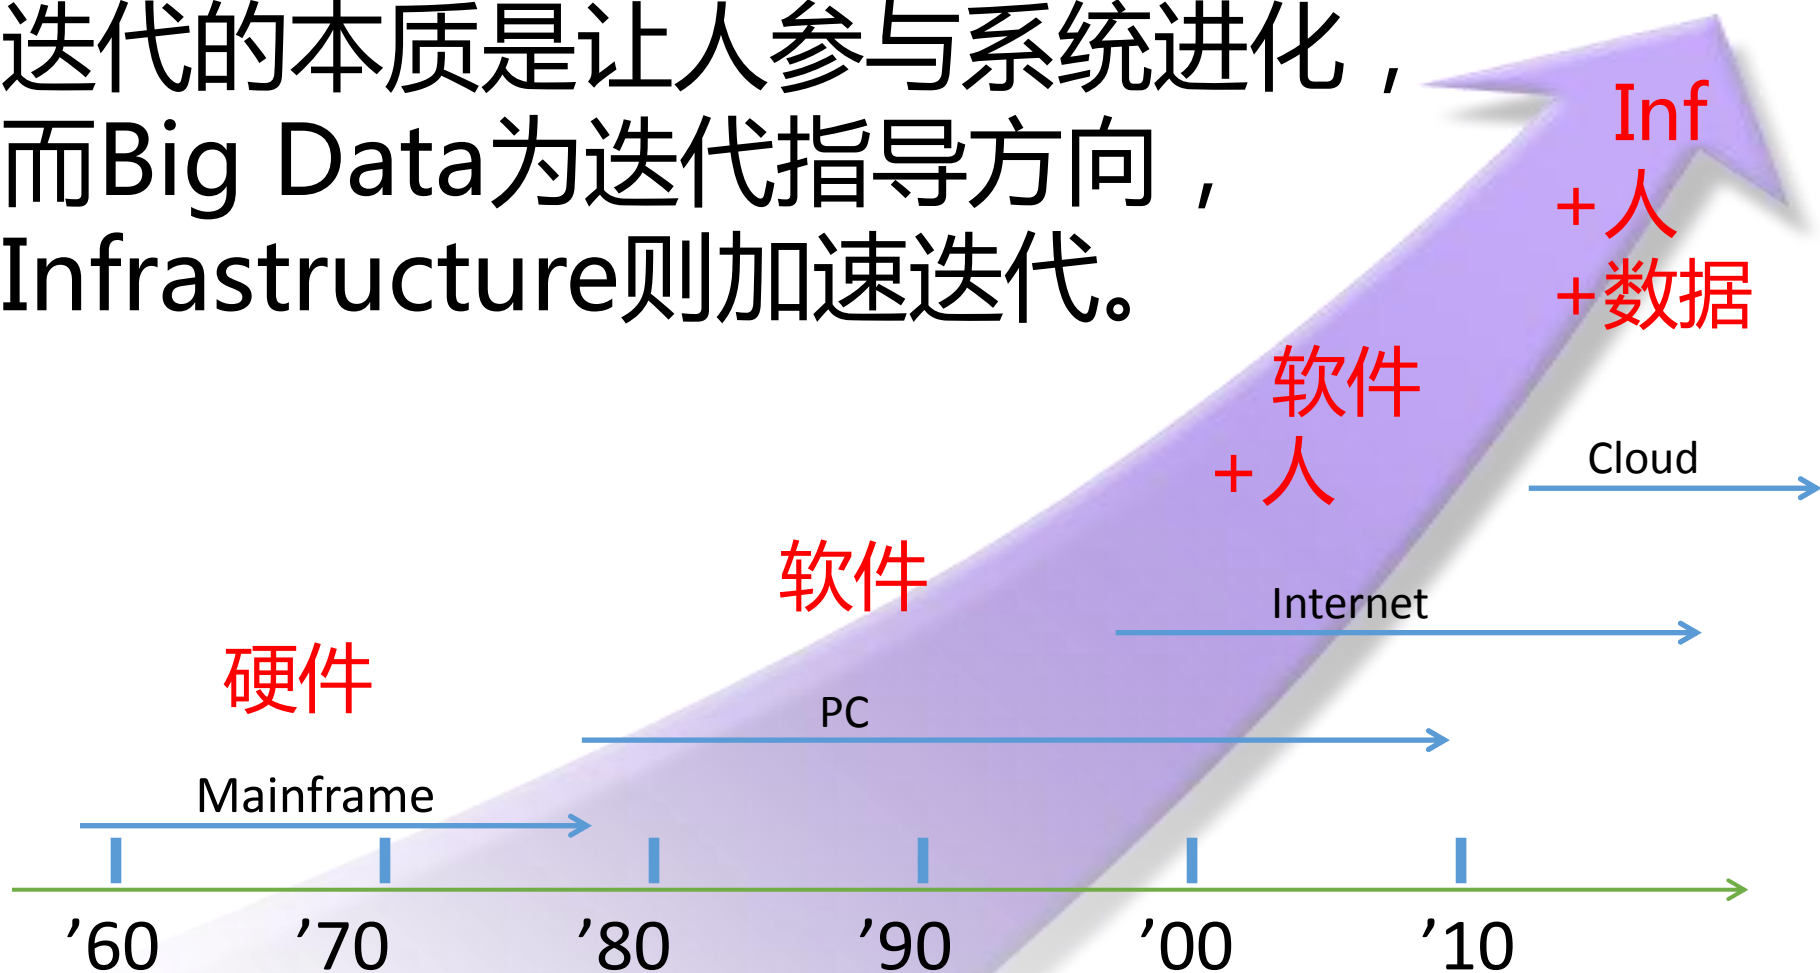
数据

架构
技术



IT产业生产力的变化

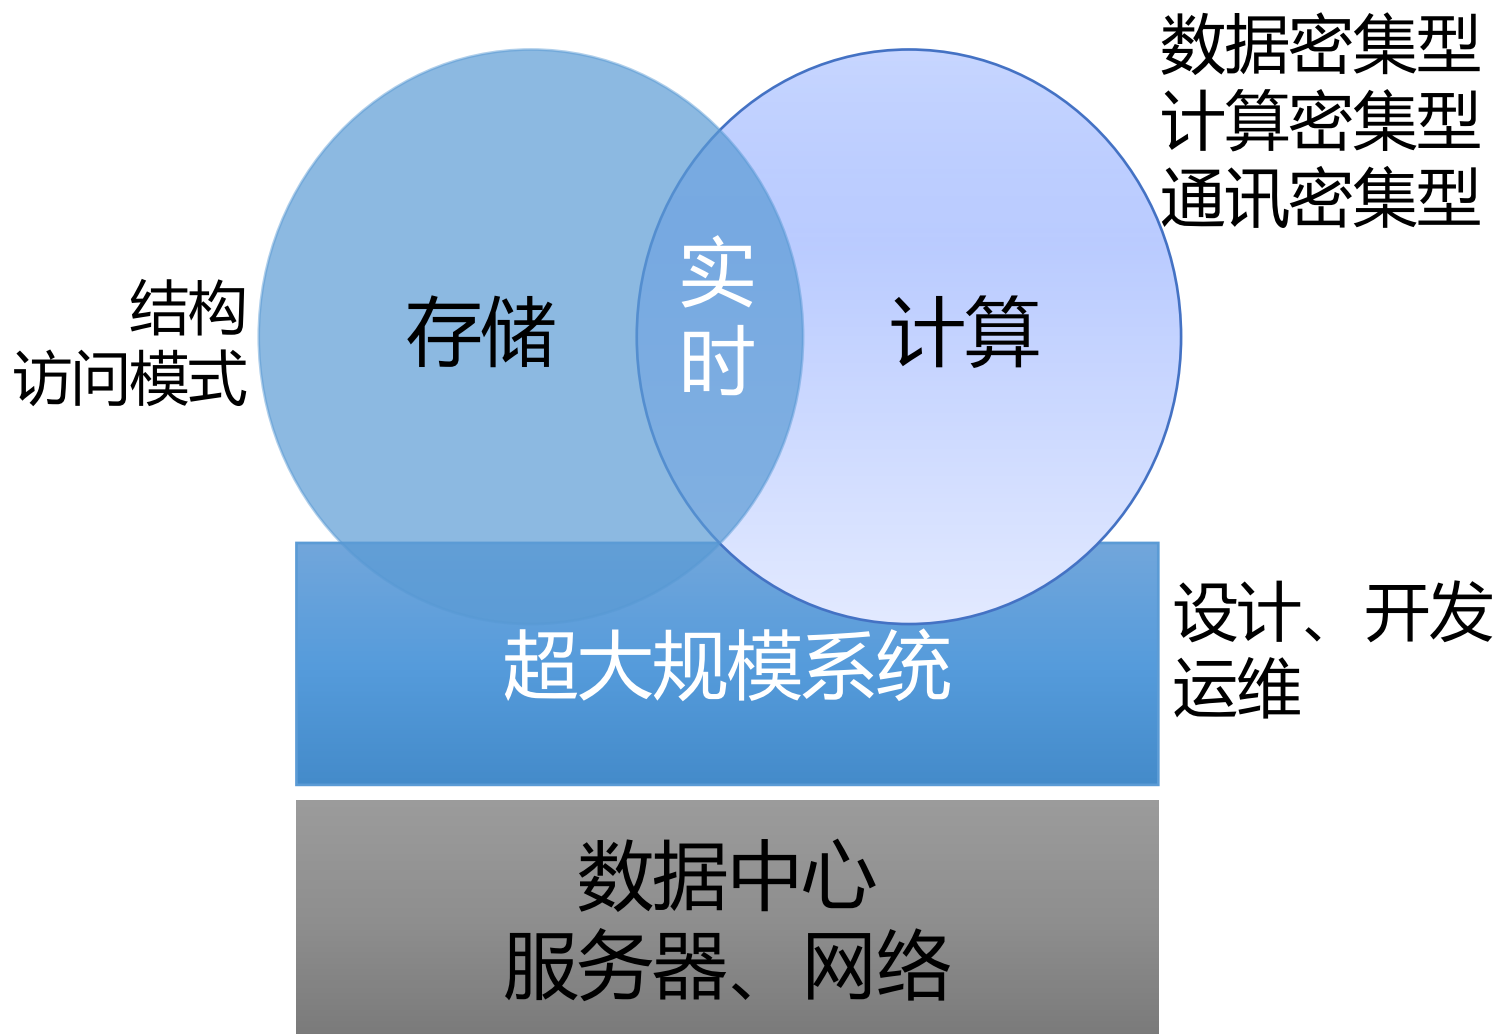
迭代的本质是让人参与系统进化，
而Big Data为迭代指导方向，
Infrastructure则加速迭代。



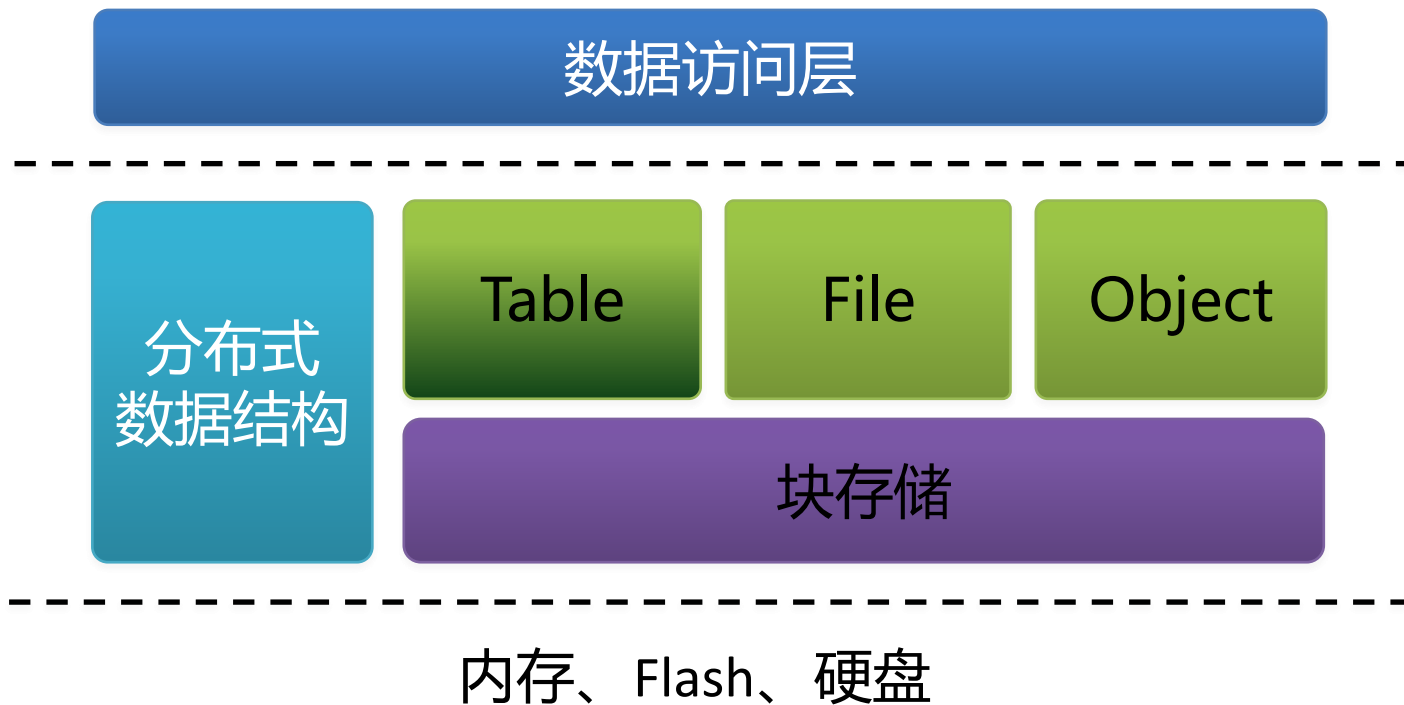
云计算技术体系



主要技术领域



分布式存储



✓统一存储体系

- 平衡大容量、高并发、低延迟
- 不同访问模式通过组合满足

✓统一访问与传输

分布式计算


表示层

SQL-like

描述能力


翻译

模型层



数据流优化
控制流管理

执行层



资源分配
优先级、并发控制
隔离、安全

实时存储与计算

图查询
平台

kNN查询
平台

机器学习
算法平台

PubSub
引擎

实时检索
平台

OLAP
引擎

向量计算引擎

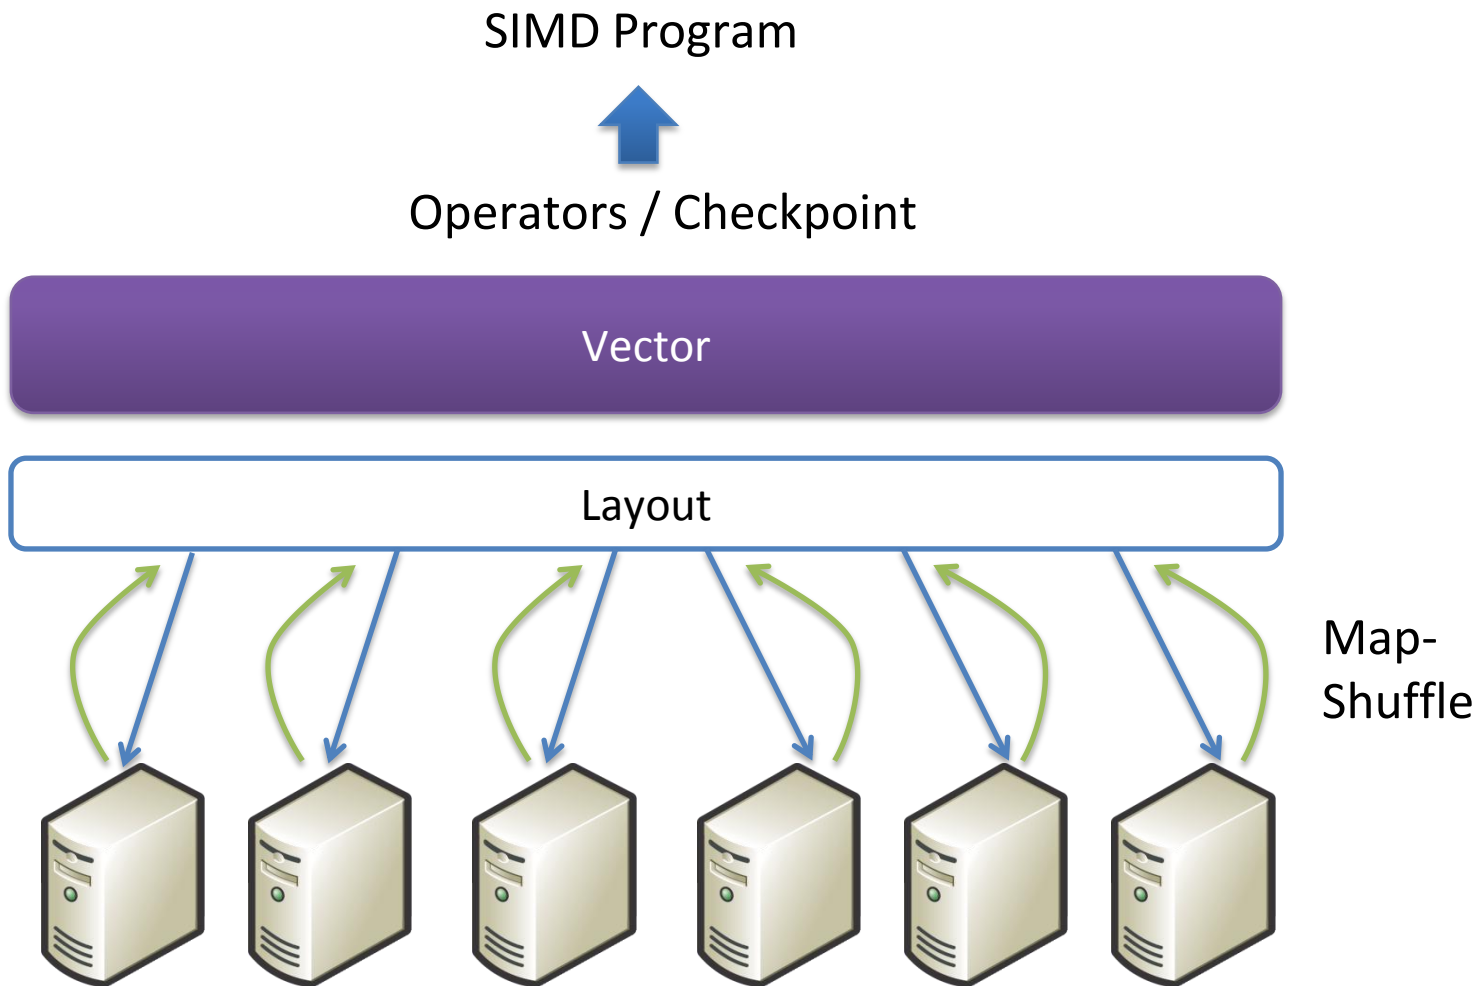
复杂事件处理引擎

流式数据处理引擎


分布式数据结构

超大规模数据仓库


向量计算引擎



复杂事件处理




average(price)
trigger(?,b,c)
filter(b)



pattern(a->b->c)
condition(func(a,b,c))

流式计算模型



$M = \text{Stream} \langle \text{window}, \text{step}, \text{bound} \rangle$

目标

海量

- 1000PB

高维、多维

- 10亿维特征训练
- 100维条件查询


实时

- 流式
- 触发式

更大、更复杂、更快!

大数据系统

人计算



大规模人工
辅助处理系统

Web Contents

分布式
存储与计算

Logs & DGC

流式处理

Machine
Learning
算法

向量引擎

PubSub

Apps

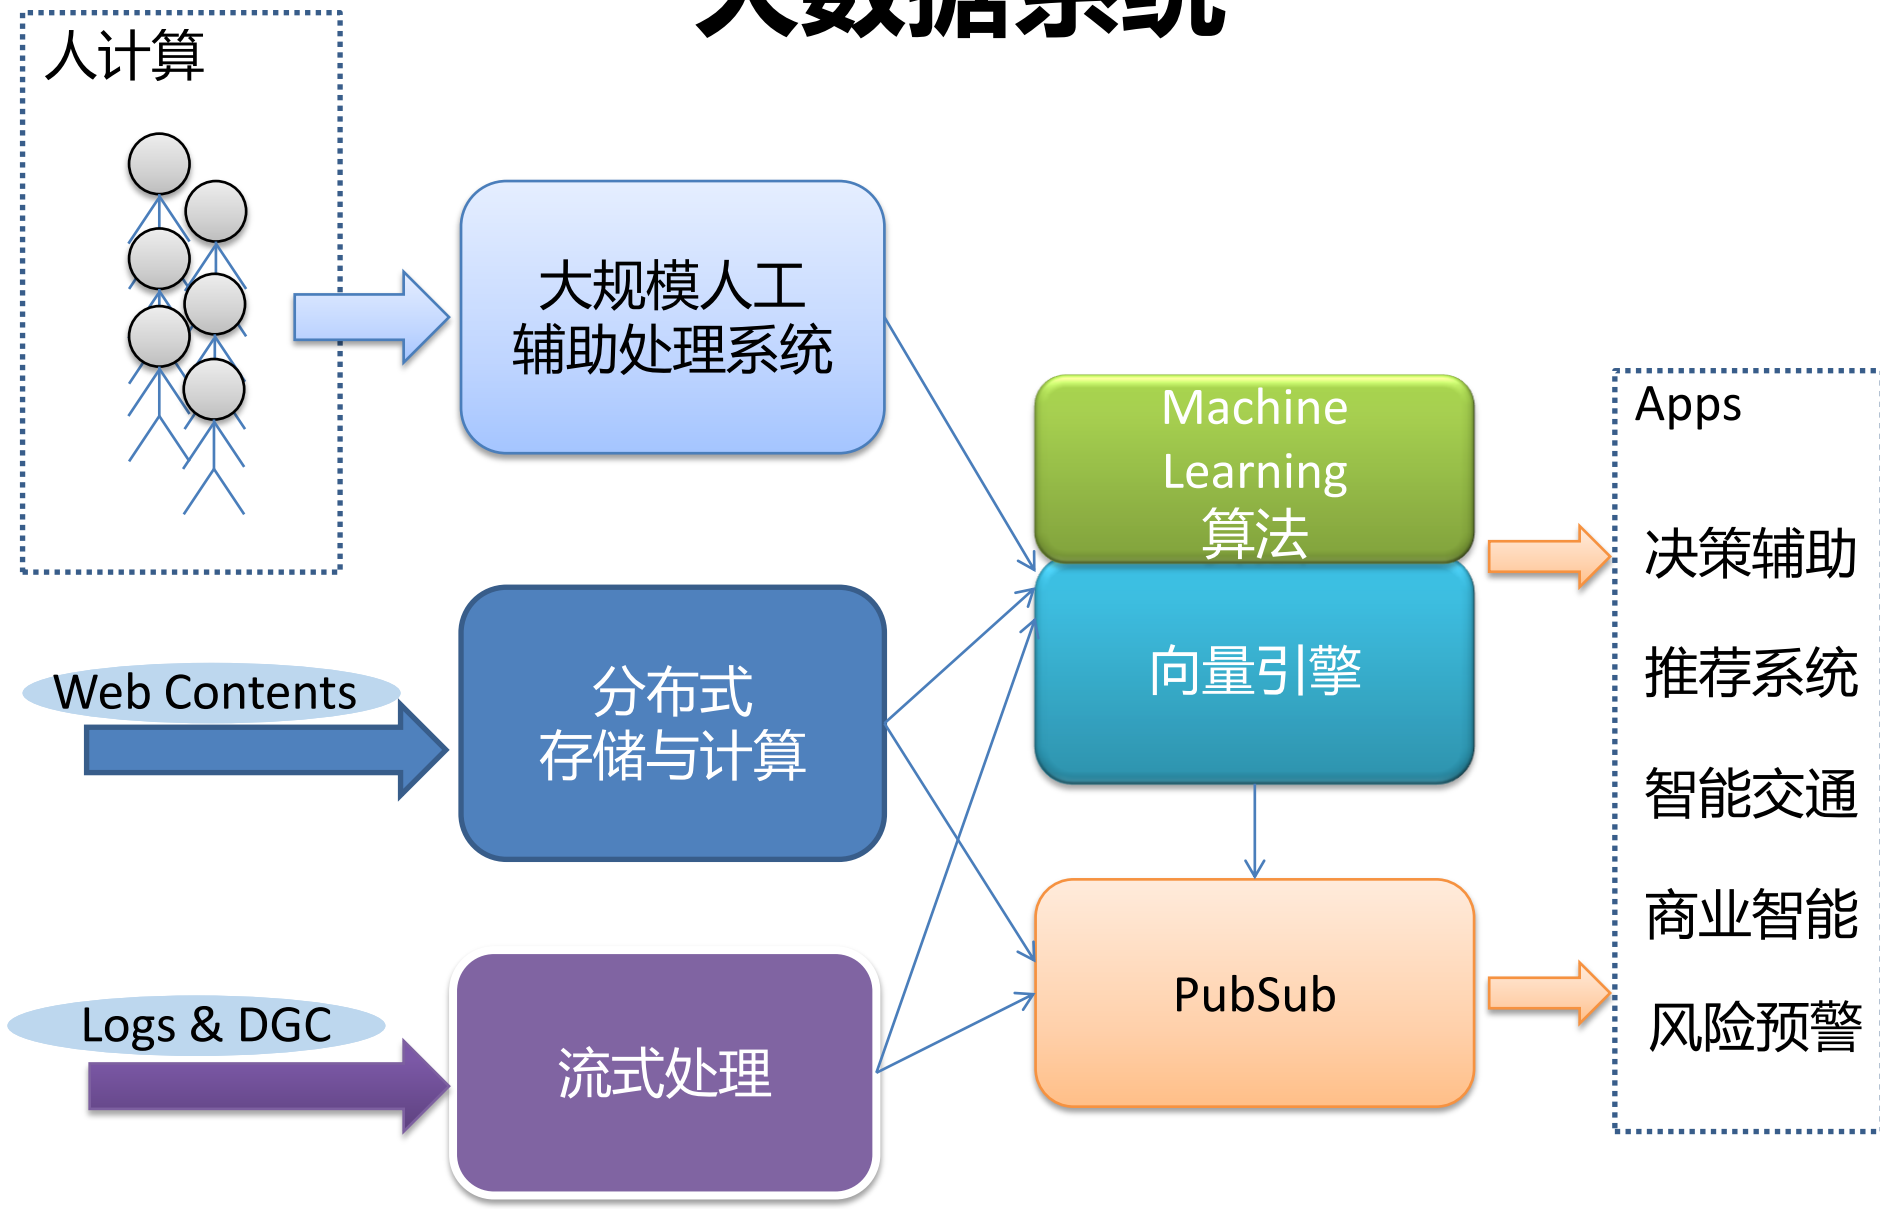
决策辅助

推荐系统

智能交通

商业智能

风险预警



第五届中国云计算大会

Thanks